

1. Considera la red neuronal convolucional definida por las capas en la columna izquierda de abajo. Completa la forma del volumen de salida y el número de parámetros en cada capa. Puede escribir las dimensiones de las activaciones en el formato (H, W, C) , donde H , W y C corresponden a la altura, el ancho y el número de canales, respectivamente. A menos que se indique lo contrario, asuma *padding* 1 y *stride* 1 cuando corresponda.

Notación:

- CONV x - N denota una capa convolucional con N filtros de altura y ancho iguales a x .
- POOL- n denota una capa de *max-pooling* de tamaño $n \times n$, con *stride* n y *padding* 0.
- FLATTEN aplana sus entradas.
- FC- N denota una capa completamente conectada con N neuronas.

Capa	Dimensiones del volumen de activación	Número de parámetros
Entrada	$32 \times 32 \times 3$	0
CONV3-8		
Leaky ReLU		
POOL-2		
BATCHNORM		
CONV3-16		
Leaky ReLU		
POOL-2		
FLATTEN		
FC-10		

2. Te encuentras con una función no lineal que devuelve 1 si su entrada es no negativa, y 0 en caso contrario, es decir,

$$f(x) = \begin{cases} 1 & \text{si } x \geq 0 \\ 0 & \text{si } x < 0 \end{cases}$$

Un amigo te recomienda usar esta no linealidad en tu red neuronal convolucional junto con el optimizador Adam. ¿Seguirías su consejo? ¿Por qué sí o por qué no?

3. Las operaciones convolucionales cumplen un papel fundamental en el campo del aprendizaje profundo, especialmente en el procesamiento y comprensión de datos de imágenes. Estas operaciones ayudan a extraer características importantes de los datos de entrada mediante la aplicación de filtros que capturan jerarquías espaciales y patrones.

En este ejercicio, dada una matriz de entrada I y un filtro F , representados como:

$$I = \begin{bmatrix} 0 & 2 & 1 & 2 \\ 0 & 3 & 2 & 2 \\ 0 & 2 & 1 & 1 \\ 1 & 0 & 1 & 0 \end{bmatrix} \quad F = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Se deberá aplicar el filtro F sobre la matriz de entrada I usando operaciones de convolución 2D bajo distintas configuraciones de *padding* y *stride*. Se deberá calcular las matrices de salida para las siguientes configuraciones:

- Aplicar F sobre I con $Padding = 0$ y $Stride = 1$.
 - Aplicar F sobre I con $Padding = 0$ y $Stride = 2$.
 - Aplicar *max pool* sobre I con un filtro de 2×2 y $Stride = 2$.
 - Aplicar F sobre I con $Padding = 1$ y $Stride = 1$.
- Considere dos redes neuronales que mapean una entrada x a una salida y . La primera red tiene una capa oculta, con 95 neuronas. La segunda red es profunda y tiene 10 capas, cada una con 5 neuronas. ¿Cuántos parámetros tiene cada red? ¿Cuál se ejecutaría más rápido?
 - Indique si la siguiente afirmación es verdadera, falsa o si depende, justificando su respuesta en no más de 4 líneas: *A medida que aumenta el número de capas convolucionales y de pooling en una CNN, el error de entrenamiento disminuirá.*
 - Indique si la siguiente afirmación es verdadera, falsa o si depende, justificando su respuesta en no más de 4 líneas: *En MobileNet, reemplazar una convolución estándar por una convolución separable en profundidad (depthwise separable convolution) siempre reduce el número de parámetros y el costo computacional sin afectar la capacidad de representación de la red.*
 - Ejecutamos el algoritmo de descenso de gradiente estocástico durante 1000 iteraciones sobre un conjunto de datos de tamaño 100, usando un tamaño de batch de 20. ¿Durante cuántas épocas entrenamos el modelo?
 - Considérese un problema de regresión lineal con dos características x_1 y x_2 , donde x_1 toma valores en el rango $[8, 9]$ y x_2 toma valores en el rango $[8000, 9000]$.
Comente por qué el gradiente descendente probablemente se desempeñará de manera más eficiente después de normalizar las características, proponga un conjunto de entrenamiento con tres ejemplos y muestre el resultado.